

# **CENTRO DE ENSEÑANZA TÉCNICA Y SUPERIOR**



Escuela de Ingeniería  
Ingeniería en Ciencias Computacionales  
Aprendizaje Profundo

Profesor:  
Dr. Ulises Orozco

## **Tarea 1**

### **The Deep Learning Revolution**

Presenta:  
Rodrigo Alberto Amaro González

Tijuana, Baja C., 23 de  
Enero del 2025

# La revolución del aprendizaje profundo

El aprendizaje automático es hoy en día uno de los campos tecnológicos más importantes y de más rápido crecimiento. Las aplicaciones del aprendizaje automático se están volviendo ubicuas, y las soluciones aprendidas a partir de los datos están desplazando cada vez más a los algoritmos tradicionales diseñados a mano. Esto no solo ha llevado a un mejor rendimiento de las tecnologías existentes, sino que también ha abierto la puerta a una vasta gama de nuevas capacidades que serían impensables si los nuevos algoritmos tuvieran que ser diseñados explícitamente a mano.

Una rama particular del aprendizaje automático, conocida como aprendizaje profundo, ha surgido como un marco excepcionalmente poderoso y de propósito general para aprender a partir de los datos. El aprendizaje profundo se basa en modelos computacionales llamados redes neuronales que originalmente se inspiraron en los mecanismos de aprendizaje y procesamiento de información en el cerebro humano. El campo de la inteligencia artificial, o IA, busca recrear las poderosas capacidades del cerebro en las máquinas, y hoy en día los términos aprendizaje automático e IA a menudo se utilizan indistintamente.

## El impacto del aprendizaje profundo

Comenzaremos nuestra discusión sobre el aprendizaje automático considerando cuatro ejemplos de diversos campos para ilustrar la enorme amplitud de aplicabilidad de esta tecnología e introducir algunos conceptos y terminología básicos. Lo que es particularmente notable sobre estos y muchos otros ejemplos es que todos ellos se han abordado utilizando variantes del mismo marco fundamental del

aprendizaje profundo. Esto contrasta marcadamente con los enfoques convencionales en los que se abordan diferentes aplicaciones utilizando técnicas ampliamente diferentes y especializadas.

## Diagnóstico médico

Primero, consideremos la aplicación del aprendizaje automático al problema del diagnóstico del cáncer de piel. El melanoma es el tipo más peligroso de cáncer de piel, pero es curable si se detecta a tiempo. Distinguir entre estas dos clases de imágenes es claramente un desafío muy grande, y sería virtualmente imposible escribir un algoritmo a mano que pudiera clasificar con éxito tales imágenes con un nivel razonable de precisión.

Este problema se ha abordado con éxito utilizando aprendizaje profundo. La solución se creó utilizando un gran conjunto de imágenes de lesiones, conocido como conjunto de entrenamiento, cada una de las cuales se etiqueta como maligna o benigna, donde las etiquetas se obtienen de una prueba de biopsia que se considera que proporciona la clase verdadera de la lesión. El conjunto de entrenamiento se utiliza para determinar los valores de aproximadamente 25 millones de parámetros ajustables, conocidos como pesos, en una red neuronal profunda. Este proceso de establecer los valores de los parámetros a partir de los datos se conoce como aprendizaje o entrenamiento.

## Estructura de proteínas

Las proteínas a veces se llaman los ladrillos de los organismos vivos. Una vez que se ha sintetizado una proteína dentro de una célula viva, se pliega en una estructura tridimensional

compleja cuyo comportamiento e interacciones se determinan en gran medida por su forma. Calcular esta estructura 3D, dada la secuencia de aminoácidos, ha sido un problema abierto fundamental en biología durante medio siglo que había visto un progreso relativamente pequeño hasta la llegada del aprendizaje profundo.

Un modelo de aprendizaje profundo se puede entrenar para tomar una secuencia de aminoácidos como entrada y generar la estructura 3D como salida, donde los datos de entrenamiento consisten en un conjunto de proteínas para las cuales se conocen tanto la secuencia de aminoácidos como la estructura 3D. La predicción de la estructura de proteínas es por lo tanto otro ejemplo de aprendizaje supervisado.

## Síntesis de imágenes

En los dos ejemplos discutidos hasta ahora, una red neuronal aprendió a transformar una entrada (una imagen de piel o una secuencia de aminoácidos) en una salida (una clasificación de lesiones o una estructura 3D de proteínas, respectivamente). Ahora nos volvemos hacia un ejemplo donde los datos de entrenamiento consisten simplemente en un conjunto de imágenes de muestra y el objetivo de la red entrenada es crear nuevas imágenes del mismo tipo.

Esta es una ejemplo de aprendizaje no supervisado porque las imágenes no están etiquetadas, a diferencia de los ejemplos de clasificación de lesiones y estructura de proteínas. Estas imágenes sintéticas son de una calidad excepcional y puede ser difícil distinguirlas de fotografías de personas reales.

## Modelos de lenguaje a gran escala

Uno de los avances más importantes en el aprendizaje automático en los últimos años ha sido el desarrollo de modelos poderosos para procesar el lenguaje natural y otras formas de datos secuenciales como el código fuente. Un modelo de lenguaje a gran escala, o LLM, utiliza el aprendizaje profundo para construir representaciones internas ricas que capturan las propiedades semánticas del lenguaje.

Estos modelos pueden exhibir capacidades extraordinarias que se han descrito como los primeros indicios de una inteligencia artificial general emergente. Son capaces de generar texto de una manera que parece indistinguible del lenguaje producido por los humanos, y pueden realizar una amplia variedad de tareas relacionadas con el procesamiento del lenguaje natural.

## Un ejemplo tutorial

Para el recién llegado al campo del aprendizaje automático, muchos de los conceptos básicos y gran parte de la terminología se pueden introducir en el contexto de un ejemplo sencillo que involucre el ajuste de un polinomio a un pequeño conjunto de datos sintéticos. Este es una forma de problema de aprendizaje supervisado en el que nos gustaría hacer una predicción para una variable objetivo, dada la valor de una variable de entrada.

Nuestro objetivo es explotar este conjunto de entrenamiento para predecir el valor de la variable objetivo para algún nuevo valor de la variable de entrada. Esto implica intentar descubrir implícitamente la función subyacente  $\sin(2x)$  que generó los datos. Esto es intrínsecamente un problema difícil, ya que tenemos que generalizar a partir de un conjunto de datos finito a una función entera.

A medida que aumentamos el orden del polinomio, vemos que el error de entrenamiento disminuye, pero el error de prueba a menudo aumenta, lo que indica un problema de sobreajuste. Esto se debe a que los polinomios de mayor orden se van ajustando cada vez más a los detalles aleatorios de los datos de entrenamiento, lo que resulta en una pobre capacidad de generalización a nuevos datos.

Podemos abordar este problema de sobreajuste mediante el uso de técnicas de regularización, que implican agregar un término de penalización a la función de error para desalentar que los coeficientes tengan magnitudes grandes. Esto controla la complejidad efectiva del modelo y, por lo tanto, determina el grado de sobreajuste.

## Conclusión

La revisión de este capítulo sobre la revolución del aprendizaje profundo ha ampliado significativamente mi conocimiento y comprensión sobre los orígenes y el desarrollo de esta poderosa técnica de aprendizaje automático. Los numerosos ejemplos concretos de aplicaciones en áreas como el diagnóstico médico, la predicción de la estructura de proteínas y la síntesis de imágenes me han dado una apreciación de la enorme versatilidad y potencial del aprendizaje profundo. Particularmente fascinante fue el análisis de los modelos de lenguaje a gran escala y su potencial para exhibir capacidades que se han descrito como indicios de una inteligencia artificial general emergente. El detallado recorrido por el ejemplo tutorial de ajuste de polinomios también me ayudó a consolidar mi comprensión de conceptos clave como el sobreajuste y la regularización, y cómo se aplican en el contexto del aprendizaje profundo. En general, este capítulo ha sido una valiosa adición a mi conocimiento sobre los

orígenes, los principios y las aplicaciones del aprendizaje profundo, y me siento mejor preparado para abordar los temas más avanzados que se presentarán en el resto del libro.

# Referencias

James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). An introduction to statistical learning (2023rd ed.). New York, NY: Springer.